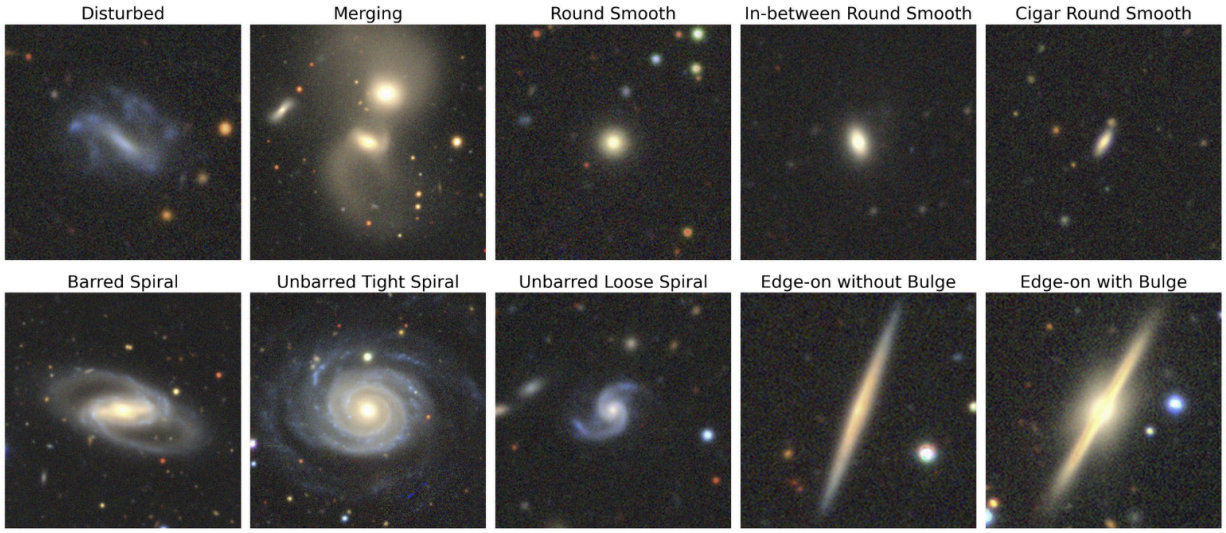
# Лабораторна 2. Класифікація галактик Galaxy10 DECaLS

Підготувала Баран Вікторія, група 1

Репозиторій: https://github.com/viktoriyabaran/galaxy10-decals-classification

## 1. Набір даних

Для виконання лабораторної роботи був використаний датасет Galaxy10 DECaLS, який містить 17 736 кольорових зображень галактик (256x256), які волонтери Galaxy Zoo розділили на 10 морфологічних класів.




Galaxy10 DECals: Henry Leung/Jo Bovy 2021, Data: DECals/Galaxy Zoo

Класи не є збалансованими по кількості зображень: Round Smooth (клас 2) мають найбільше - 2645 зображень, а Cigar Shaped Smooth (клас 4) найменше - 334.

### Результати в літературі

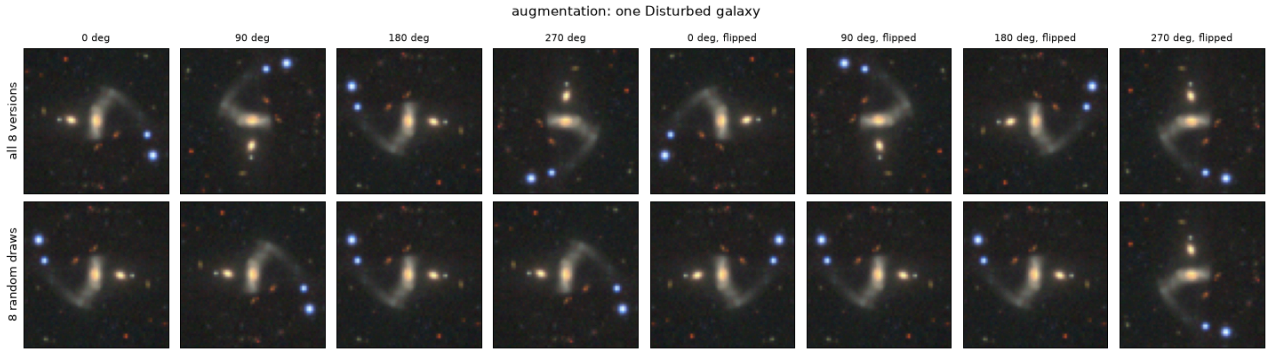
- **95,42%** - WaveMix (28 млн параметрів, попередньо навчена на ImageNet-1k, 256x256) - WaveMix (Jeevan et al., 2022), **SOTA**
- **94,86%** - гібрид трансформера і згорткової мережі - Astroformer (Dagli, 2023)
- **~64–68%** - CNN, 64x64 - You (2025), Evaluation of Galaxy Morphology Classification with ML and DL
- **38,2%** - Random Forest, 64x64 - You (2025)

### Підготовка зображень

Видалено 1 порожнє зображення і 118 дублікатів, після чого залишилось 17 556 зображень. У процесі також були створені версії зображень з різною роздільною здатністю для перевірки різниці результатів.

| Розмір | Використано для |
|---|---|
| 64x64 | моделей 1 і 2 (основні запуски) |
| 16x16, 32x32, 128x128 | експериментів моделі 1 |
| 128x128 | експерименту моделі 2 |
| 128x128, 256x256 | моделі 3 |

Для моделей 2 і 3 також була використана **аугментація**.




## Розбиття датасету

| Частина | Зображень | Частка |
|---|---|---|
| train | 12 289 | 70% |
| validation | 2 633 | 15% |
| test | 2 634 | 15% |

## 2. Модель 1. Random Forest

**58,1% точність і macro F1 0,527 на зображеннях 64x64.**

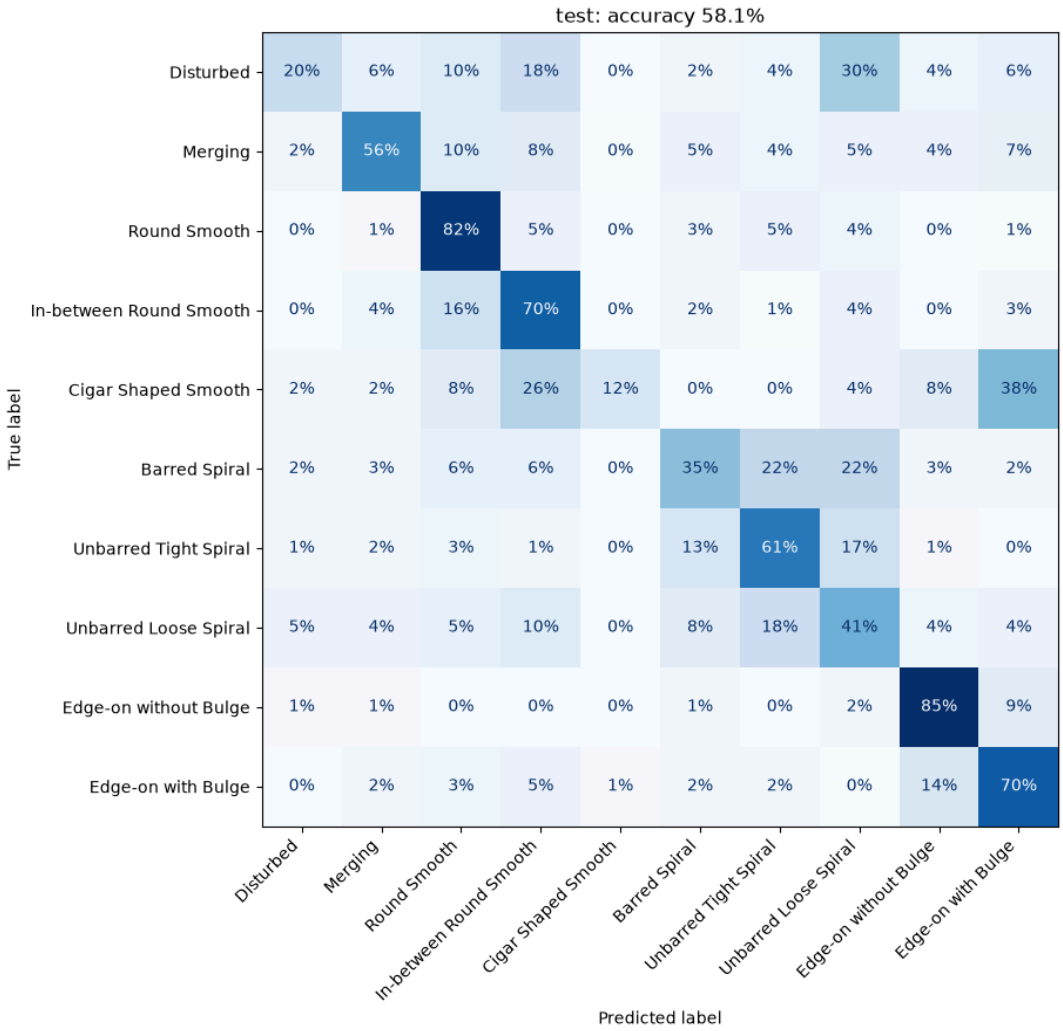
Дерева мали глибину **24–49** запитань і в середньому **~2 372** листки, дерева запам'ятовували зображення, на яких тренувалась, адже точність на них становила 100%.

Головне обмеження полягало в тому, що модель не знала, які пікселі сусідні, відповідно не могла розпізнати ту саму форму, яка просто знаходилась під іншим кутом.

### Час (Apple M4, 10 ядер CPU)

| Етап | Зображень | Час | На зображення |
|---|---|---|---|
| train | 12 289 | 15,86 с | 1,290 мс |
| validation | 2 633 | 0,07 с | 0,027 мс |
| test | 2 634 | 0,07 с | 0,028 мс |

### Матриця помилок



### Експерименти

Також були проведені декілька експериментів, які змінювали щось одне порівняно з основним запуском:

| Варіант | Точність моделі | Macro F1 моделі |
|---|---|---|
| **основний (64x64)** | **58,6%** | **0,541** |
| 16x16 | 56,0% | 0,516 |
| 32x32 | 58,9% | 0,537 |
| 128x128 | 59,0% | 0,541 |
| Стиснення PCA-50 | 57,4% | 0,532 |
| Стиснення PCA-256 | 53,1% | 0,478 |
| min_samples_leaf = 5 | 58,0% | 0,546 |

Можна помітити, що починаючи з 32x32 точність моделі практично не зростає, адже ліс не вміє використовувати дрібні деталі.

Крім того, стиснення PCA-256, яке використали у статті You 2025 року, знижує точність на 5,5 відсоткових пунктів, тому в основному запуску його краще не використовувати.

## 3. Модель 2. Мала згорткова мережа (CNN)

**79,5% точність і macro F1 0,779 на зображеннях 64x64.**

Мережа складалася з чотирьох однакових блоків. Кожен блок проходив маленькими фільтрами 3x3, які шукали певний візерунок (край, пляму, дугу): перший блок по самому зображенню, а кожен наступний - по результатах попереднього. Після відпрацювання одного блоку ми отримували так звану "карту знахідок", яка для кожного місця зберігала число - наскільки сильно там проявився візерунок. Цю карту той самий блок наприкінці зменшував вдвічі, залишаючи з кожного квадрата 2x2 лише найбільше число, тобто місце, де візерунок проявився найсильніше.

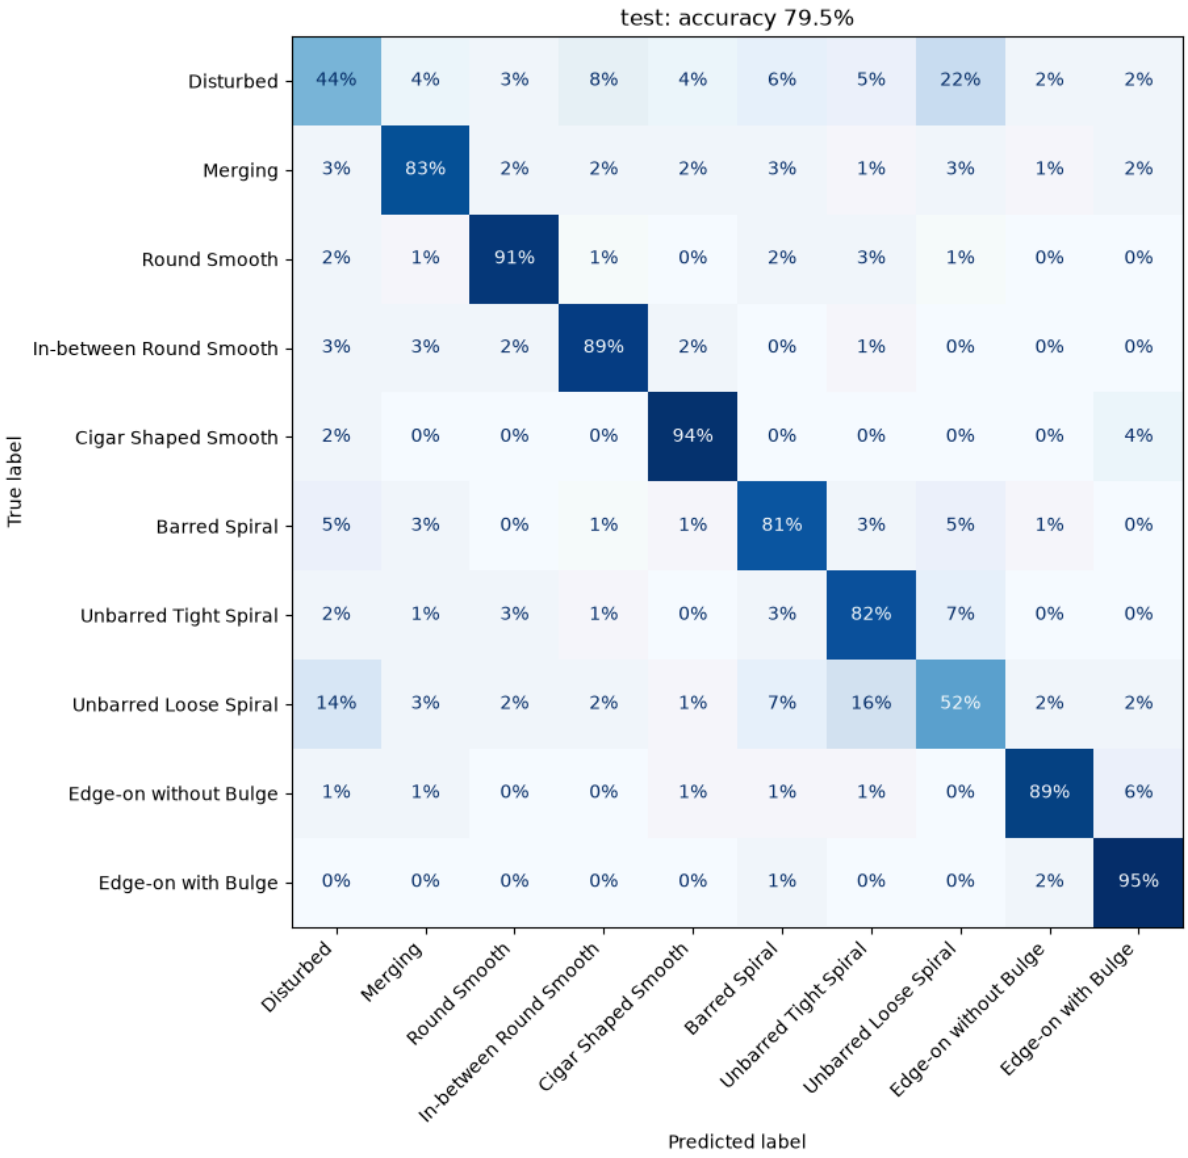
Наприкінці мережа перетворювала всі знахідки на 10 оцінок по одній на клас, і обирала клас із найбільшою оцінкою. Усього вона мала **391 946** параметрів, з яких майже всі були у фільтрах згортки.

Головна перевага порівняно з Random Forest полягала в тому, що згорткові фільтри дивились на сусідні пікселі разом і знаходили ту саму форму в будь-якому місці зображення, а аугментація навчила мережу розпізнавати її під будь-яким кутом.

**Час (Apple M4, GPU)**

| Етап | Зображень | Час | На зображення |
|---|---|---|---|
| train | 12 289 | 354,4 с (~6 хв; 7,09 с на епоху) | 28,841 мс |
| validation | 2 633 | 0,46 с | 0,176 мс |
| test | 2 634 | 0,49 с | 0,184 мс |

**Матриця помилок**



### Експерименти

Було проведено декілька експериментів, які змінювали щось одне порівняно з основним запуском:

| Варіант | Точність моделі | Macro F1 моделі |
|---|---|---|
| **основний (64x64)** | **79,8%** | **0,778** |
| без аугментації | 69,7% | 0,652 |
| 128x128 | 78,1% | 0,759 |

Очевидно, що без аугментації мережа перенавчається (overfitting): вона дедалі краще запам'ятовувала навчальні зображення, але на нових її результати не покращувались з кожною епохою, тому навчання зупинилось раніше, ніж в основному запуску. Аугментація дає близько 10 відсоткових пунктів точності.

Результати другого експерименту показали, що використання зображень 128x128 для цієї моделі та датасету не принесло покращеного результату: точність моделі не стала вищою, а її навчання зайняло в 3,9 рази довше.

## 4. Модель 3. Попередньо навчена мережа ConvNext-Tiny

**87,3% точність і macro F1 0,858 на зображеннях 128x128.**

ConvNext-Tiny (Liu et al., 2022) - сучасна згорткова мережа, яка була попередньо навчена на 1,2 млн звичайних фотографій із 1000 класів ImageNet. Я дотренувала її на зображеннях галактик з цього датасету.

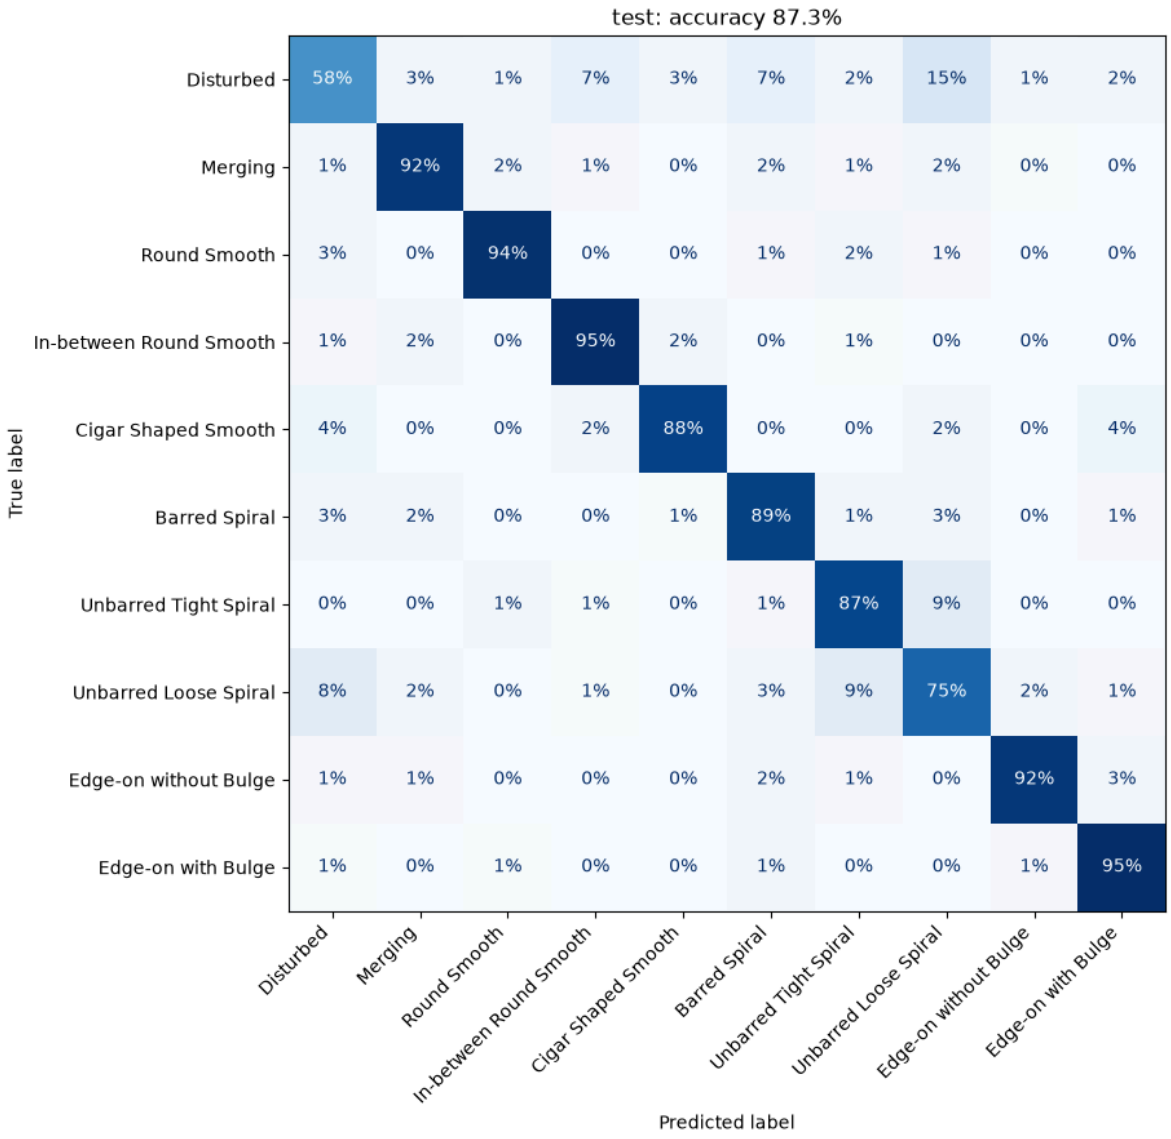
Останній шар мережі, який розрізняв 1000 класів ImageNet, я замінила новим з 10 класами галактик. Усього мережа мала 27 827 818 параметрів, тобто приблизно у 70 разів більше, ніж мала CNN.

Перевага попереднього навчання була помітна одразу, адже вже після першої епохи мережа мала 75,6% точності на валідації, тобто майже таке ж число, яке мала CNN досягла за 50 епох (79,8%).

### Час (Apple M4, GPU)

| Етап | Зображень | Час | На зображення |
|---|---|---|---|
| train | 12 289 | 2 543,6 с (~42 хв; 169,6 с на епоху) | 206,983 мс |
| validation | 2 633 | 6,24 с | 2,372 мс |
| test | 2 634 | 6,38 с | 2,423 мс |

## Матриця помилок




## Експерименти

| Варіант | Точність моделі | Macro F1 моделі |
|---|---|---|
| **основний (128x128, 15 епох)** | **87,2%** | **0,860** |
| рання зупинка (після 4 епох без покращення) | 85,9% | 0,843 |
| 256x256 | 87,5% | 0,862 |

Рання зупинка, яка мала на меті перестати витрачати ресурси, коли не було покращень у точності протягом останніх 4 епох, в результаті зашкодила мережі. Навчання зупинилось після 9 епох, коли швидкість навчання ще не встигла знизитись, і втратила 1,3 в.п. точності. Саме тому в основному запуску мережа навчалась усі 15 епох.

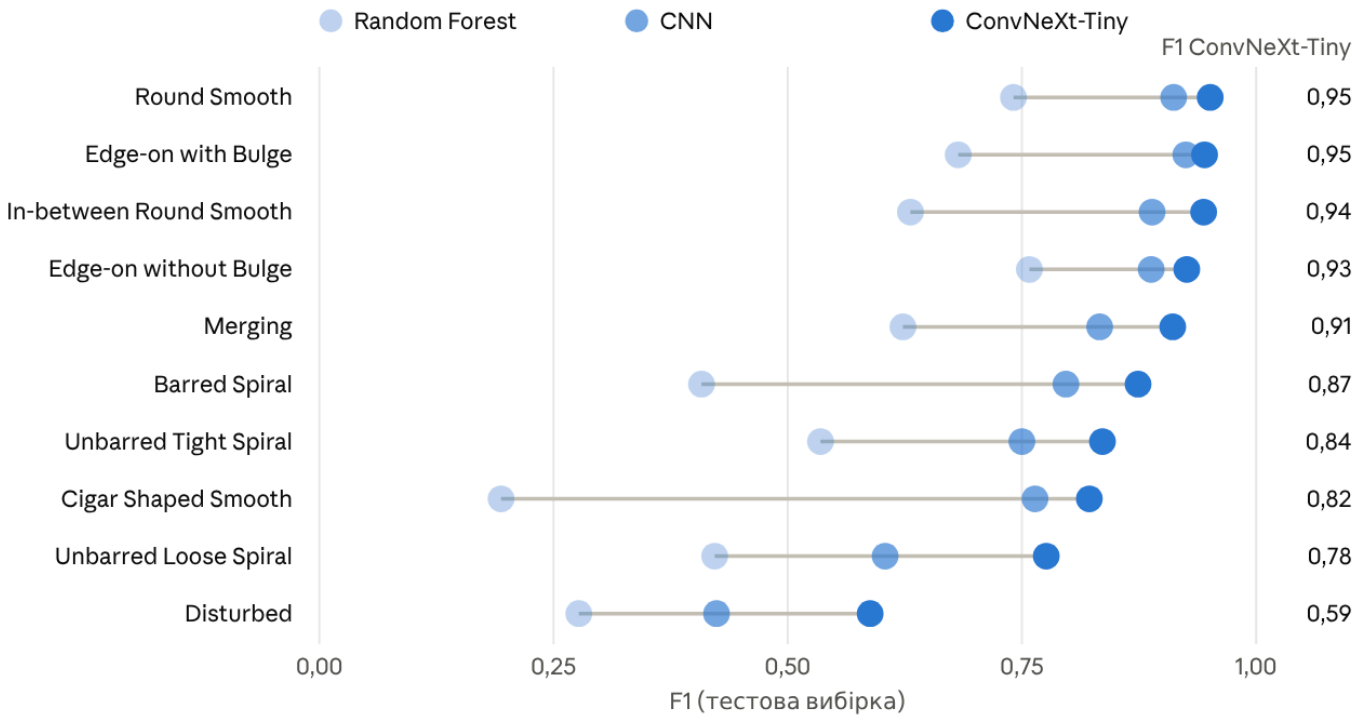
Експеримент з використанням зображень 256x256 дав лише +0,3 в.п. точності, але навчання тривало майже в 4 рази довше (158 хв проти 42 хв).

## 5. Порівняння моделей

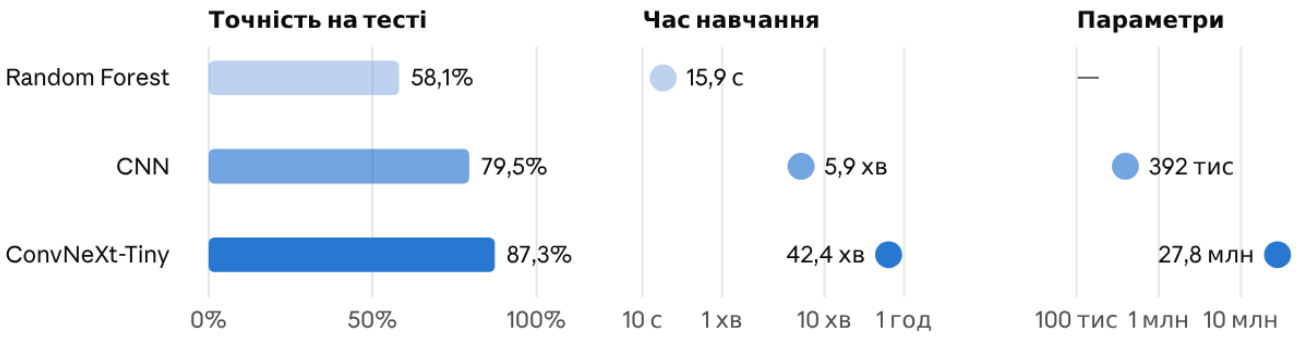
На тестовій вибірці кожна складніша модель точніша: Random Forest - 58,1%, CNN - 79,5%, ConvNext-Tiny - 87,3%.

| Модель | Точність | Macro F1 | Навчання | Фінальне передбачення (2 634 зобр.) |
|---|---|---|---|---|
| Random Forest | 58,1% | 0,527 | 15,9 с | 0,07 с |
| CNN | 79,5% | 0,779 | 354 с (~6 хв) | 0,49 с |
| ConvNext-Tiny | 87,3% | 0,858 | 2 544 с (~42 хв) | 6,38 с |

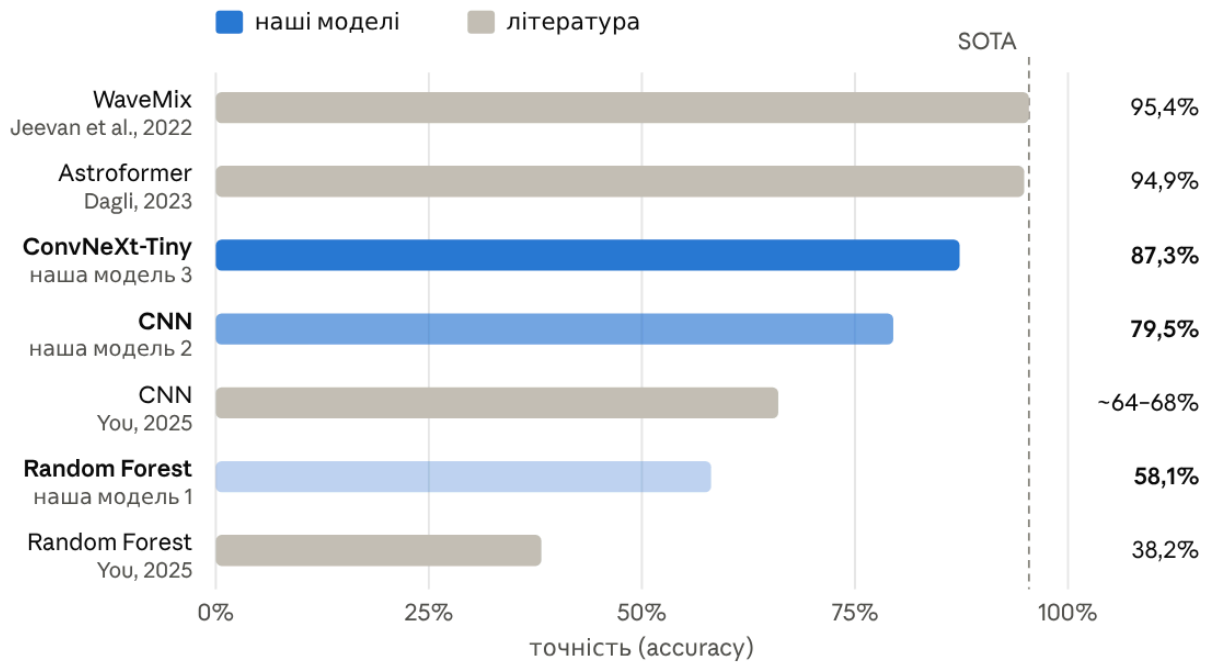
### F1 по класах



## Порівняння моделей




## Наші моделі порівняно з літературою




Найкраща модель, ConvNext-Tiny, на тесті точніша за CNN на 7,8 в.п. і за RF - на 29,2.

Від SOTA (WaveMix, 95,42%) її відділяє близько 8 пунктів. WaveMix має таку саму кількість параметрів (28 млн), але навчалась на зображеннях 256x256 із сильнішою аугментацією (TrivialAugment) і на оригінальному наборі даних (17 736 зображень, разом із дублікатами).